

# **Rachunek Prawdopodobieństwa**

**Prof. dr hab. Mieczysław Wodecki**

## **Zasady zaliczeń**

**Forma zaliczenia – zaliczenie na ocenę (kolokwium - na ostatnim wykładzie).**

**Termin poprawkowy – w sesji.**

## **Rachunek Prawdopodobieństwa\*(w. 15)**

- 1. Elementy statystyki – miary położenia, rozproszenia**
- 2. Przestrzeń zdarzeń elementarnych. Własności prawdopodobieństwa. Prawdopodobieństwo klasyczne i geometryczne**
- 3. Prawdopodobieństwo warunkowe. Wzór Bayesa. Niezależność zdarzeń.**
- 4. Zmienne losowe (rozkłady: dwumianowy, Poissona, normalny, wykładniczy).**
- 5. Parametry zmiennych losowych, standaryzacja, tablice.**
- 6. Wartości oczekiwane, wariancje, mediany i kwartale wybranych rozkładów.**
- 7. Zmienne losowe dwuwymiarowe. Rozkłady brzegowe. Niezależność zmiennych losowych. Współczynnik korelacji.**
- 8. Ciągi zmiennych losowych: sumowanie niezależnych zmiennych losowych. Prawo wielkich liczb (słabe).**

### **Literatura**

- 1. H. Jasiulewicz, W. Kordecki, Rachunek prawdopodobieństwa i statystyka matematyczna.**
- 2. A. Plucińska, E. Pluciński, Probabilistyka, WNT, Warszawa 2006.**

---

*\* dokładny program oraz pełny spis literatury są zamieszczone w Sylabusie.*

**Rachunek prawdopodobieństwa (inaczej probabilistyka) jest działem matematyki, który zajmuje się modelowaniem zjawisk (zdarzeń) przypadkowych (losowych). Czyli takich, których wyniku zakończenia nie da się w sposób jednoznaczny przedstawić.**

**Poszukuje się prawidłowości dotyczących możliwości uzyskania oczekiwanego wyniku zdarzeń losowych. Powstanie tego działu matematyki (XVII wiek) było związane z hazardem i poznania szans na wygranę w konkretnej grze losowej.**

**Dziś osiągnięcia tej dziedziny nauki wykorzystuje się w wielu innych dziedzinach, takich jak nauki przyrodnicze, społecznych i techniczne.**

**Elementy rachunku prawdopodobieństwa są stosowane, między innymi w:**

- metodach Monte Carlo,
- sieciach neuronowych,
- uczeniu maszynowym,
- różnego rodzaju zadaniach optymalizacji i klasyfikacji.

**Elementy probabilistyki są także stosowane w informatyce:**

- modelowanie procesów z niepewnymi (np. losowymi) parametrami,
- algorytmy zrandomizowane (losowy wybór w trakcie działania), np. algorytm: genetyczny, mrówkowy, symulowanego wyżarzania, itd.,
- analiza probabilistyczna algorytmu („zachowanie” algorytmu na losowych danych),
- losowe eksperymenty (porównywanie wyników algorytmów – metody statystyki opisowej).

## Opracowanie danych statystycznych

**Statystyka** zajmuje się zbieraniem, opracowywaniem i analizą danych o zjawiskach masowych (nieprzewidywalnych), tj. zjawiskach powtarzających się dużą liczbę razy.

*Badanie statystyczne* umożliwia ustalenie pewnych prawidłowości (regularności), charakterystycznych wartości oraz tendencji w obserwowanych procesach. Nie można ich zazwyczaj ustalić na podstawie pojedynczych obserwacji.

Badaniu podlega **populacja** (zbiorowość statystyczna) – zbiór elementów (jednostek statystycznych) mających wspólną własność (**cechę**).

**Cecha** może przyjmować wartości:


- a) *dyskretne* (skokowe) – np. liczba dzieci w rodzinie, liczba braków, liczba wypadków,
- b) *ciągłe* (z pewnego przedziału) – np. zużycie wody, energii.

Badanie statystyczne można przeprowadzić:

1. poddając obserwacji wszystkie elementy populacji,
2. poddać obserwacji pewną reprezentację (próbę z populacji) i na tej podstawie wyciągnąć wnioski dotyczące całej populacji.

Ponieważ populacje bywają bardzo duże, stąd zazwyczaj stosuje się 2-gą metodę.

### Rozkłady cechy w populacji



## Statystyczne Opracowanie Wyników

Niech  $X$  będzie badaną cechą w pewnej populacji.

$x_1, x_2, \dots, x_n$  ciąg  $n$  wartości obserwacji cechy  $X$  (wartości próby)  
nazywamy *szeregiem statystycznym (szczegółowym)*.

Po uporządkowaniu (rosnąco lub malejąco) otrzymujemy *uporządkowany szereg statystyczny*.

### **Charakterystyki liczbowe rozkładu cechy w populacji**

Analiza danych statystycznych powinna doprowadzić do zwięzłego przedstawienia wyników. Używa się do tego odpowiednich charakterystyk (liczb) zwanych *parametrami statystycznymi* (parametrami opisu danych statystycznych). Parametry te dzieli się na:

1. miary położenia,
2. miary zmienności (rozproszenia),
3. miary asymetrii,
4. miary koncentracji.

## Miary położenia

### **Średnia arytmetyczna**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

### **Dominanta (modalna, moda)**

Wielkość  $D$  najliczniej występująca w szeregu.

Dla szeregu: 18, 21, 27, 29, 35, 43, 51    dominanta nie istnieje.

Dla szeregu: 8, 1, 2, 2, 3, 1, 4, 1, 7     $D=1$ .

### **Mediana („wartość środkowa”)**

Wielkość  $M$  taka, że co najmniej 50% obserwacji nie przekracza  $M$  ( $\leq$ ) oraz co najmniej 50% obserwacji jest nie mniejsza od  $M$  ( $\geq$ ).

Dla szeregu: 18, 21, 27, 29, 35, 43, 51     $M=29$ .

Dla szeregu: 18, 21, 27, 29, 35, 43, 51, 59

$$M=(29+35)/2=32$$

### **Kwantyle**

Kwantyl  $p$ -procentowy, to wielkość  $K_p$  taka, że co najmniej  $p\%$  obserwacji nie przekracza  $K_p$  ( $\leq$ ) oraz co najmniej  $(100-p)\%$  obserwacji jest nie mniejsza od  $K_p$  ( $\geq$ ).

3,4,6,8,13,15,16,20,21,23,25,33,44,51,52,56

$$K_{25\%} = \frac{8 + 13}{2} = 10,5$$

## Miary zmienności(zróznicowania, rozproszenia)

Wariancja (oznaczana przez  $s^2, \sigma^2, D^2$ )

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Dla Przykładu 1    18, 21, 27, 29, 35, 43, 51,     $\bar{x} = 32$ .

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{7} [(18 - 32)^2 + (21 - 32)^2 + (27 - 32)^2 + (29 - 32)^2 + (35 - 32)^2 + (43 - 32)^2 + (51 - 32)^2] = 120.2857$$

Odchylenie standardowe(oznaczana przez  $s, \sigma, D$ )

Jest to pierwiastek kwadratowy z wariancji.

Przedział  $[\bar{x} - s, \bar{x} + s]$  nazywamy typowym przedziałem zmienności. Należą do niego niemal wszystkie elementy 70% (dużo)

Współczynnik zmienności

$$V(s) = \frac{s}{\bar{x}} \bullet 100\%$$

umożliwia porównywanie zmienności różnych cech.

## Szereg rozdzielczy

Najczęściej ze względu na dużą liczbę wartości cechy w szeregu statystycznym, tworzymy szereg rozdzielczy, w których klasami są przedziały.

Dany jest szereg statystyczny  $x_1, x_2, \dots, x_n$ . Niech

$$x_{\min} = \min\{x_1, x_2, \dots, x_n\} \text{ oraz } x_{\max} = \max\{x_1, x_2, \dots, x_n\}.$$

Różnicę  $R = x_{\max} - x_{\min}$  nazywamy *rozstępem szeregu*.

Przyjmuje się, że liczba klas  $k \approx \sqrt{n}$  i zaleca się, aby

Liczba obserwacji $n$	Liczba klas $k$
40-60	6-8
60-100	7-10
100-200	9-12
200-500	11-17

Klasy są rozłącznymi przedziałami  $[x_{0,i}, x_{1,i})$ ,  $i = 1, 2, \dots, k$ , gdzie  $x_{0,i}$  oraz  $x_{1,i}$  są odpowiednio *dolną* i *górną granicą* klasy.

Różnicę  $h = x_{1,i} - x_{0,i}$  nazywamy *rozpiętością* klasy,

$$h \approx \frac{x_{\max} - x_{\min}}{k} = \frac{R}{k}.$$

### Przykład 1.

Spytano o wiek 20 losowo wybranych pracowników pewnego zakładu.

19, 22, 24, 24, 25, 25, 26, 26, 27, 29, 30, 30, 31, 32, 32, 34, 34, 35, 35, 35

$$n=20, \quad k \approx \sqrt{n} = \sqrt{20} \approx 4.$$

$$x_{\min} = \min\{x_1, x_2, \dots, x_{20}\} = 19,$$

$$x_{\max} = \max\{x_1, x_2, \dots, x_{20}\} = 35.$$

$$R = x_{\max} - x_{\min} = 35 - 19 = 16. \quad h \approx \frac{x_{\max} - x_{\min}}{k} = \frac{R}{k} = \frac{16}{4} = 4.$$

Mamy więc klasy: [19, 23), [23, 27), [27, 31), [31, 35).

**Tabela 1. Szereg rozdzielczy przedziałowy.**

numer klasy	Klasa $[x_{0,i}, x_{1,i})$	liczebność $n_i$	Częstość $n_i/n$ $\omega_i$	liczebność skumulowana $n_{sk,i}$	częstość skumulowana $\omega_{sk,i}$
-------------	----------------------------	------------------	--------------------------------	-----------------------------------	--------------------------------------



1	19-23	2	0,1	2	0,1
2	23-27	6	0,3	8	0,4
3	27-31	4	0,2	12	0,6
4	31-35	8	0,4	20	1,0

#### **UWAGI**

1. Przedstawienie w postaci szeregu rozdzielczego nie jest jednoznaczne.
2. Pomiedzy klasami nie może być luk (każdy element szeregu musi należeć do pewnej klasy. Szczególną uwagę należy zwrócić na pierwszą i ostatnią klasę (należy ewentualnie je powiększyć). Liczba elementów w każdej klasie nie może być zbyt mała, ani zbyt duża.
3. Zastępując szereg statystyczny szeregiem rozdzielczym tracimy dokładność pewnych informacji. W pewnych praktycznych zastosowaniach nie jest to istotne.
4. Liczba klas zazwyczaj nie przekracza 30.

#### **Średnia arytmetyczna**

i. Szereg rozdzielczy


$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \cdot x_i^s, \quad x_i^s - \text{środek klasy}$$

#### **Wariancja (oznaczana przez $s^2, \sigma^2, D^2$ )**

A) Szereg rozdzielczy

$$s^2 = \frac{1}{n} \sum_{i=1}^k (x_i^s - \bar{x})^2 \cdot n_i, \quad x_i^s - \text{środek klasy}$$

## Asymetria



$$\bar{x} < M < D \quad \bar{x} > M > D$$


$$\bar{x} = M = D$$

## Współczynnik koncentracji (skupienia), kurtoza K

$$K = \frac{M_4}{s^4} - 3$$

gdzie  $M_l = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^l$ , a  $s$  jest odchyleniem standardowym.

Kurtoza ma wartość 0 dla rozkładu normalnego. Gdy  $K > 0$ , to rozkład jest bardziej skupiony („szpiczasty”) niż rozkład normalny, gdy  $K < 0$ , to rozkład jest bardziej spłaszczony niż rozkład normalny.



$$\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \text{ standardowy rozkład normalny}$$